Plan projektu: Prognozowanie płaskości detalu na podstawie danych z obróbki CNC

Plan projektu

1. **Zastosowanie uczenia maszynowego w obróbce skrawaniem**
   - **1.**1. Przegląd literatury
   - **1.**2. Zastosowanie w przemyśle
   - **1.**3. Cel wykorzystania ML w niniejszym projekcie
2. **Opis problemu i cel analizy**
   - **2.**1. Charakterystyka detalu
   - **2.**2. Znaczenie płaskości powierzchni
   - **2.**3. Opis problemu
   - **2.**4. Cel analizy
3. **Zbieranie danych**
   - **3.**1. Źródła danych
   - **3.**2. Opis operacji OP10
   - **3.**3. Częstotliwość kontroli
4. **Przygotowanie oraz eksploracja danych do uczenia maszynowego**
   - **4.**1. Kodowanie sekwencji zamykania klampów
   - **4.**2. Analiza korelacji – heatmapa
   - **4.**3. Histogram płaskości detalu
5. **Budowa i ocena modelu uczenia maszynowego**
   - **5.**1. Wybór modeli regresyjnych
   - **5.**2. Podział danych i zastosowane metryki
   - **5.**3. Wyniki modeli regrysyjnych
   - **5.**4. Interpretacja wyników
   - **5.**5. Analiza róznic między wartościami rzeczywistymi a przewidywanymi
   - **5.**6. Usunięcie wartości odstających i ocena wplywu na model regresyjny
   - **5.**7. Budowa i ocena modelu klasifikacji
6. **Wnioski końcowe**

1 Zastosowanie uczenia maszynowego w obróbce skrawaniem

W ostatnich latach uczenie maszynowe zyskało na znaczeniu jako narzędzie wspierające rozwój nowoczesnych technologii produkcyjnych. W kontekście przemysłu 4.0, ML umożliwia analizę dużych zbiorów danych generowanych przez maszyny CNC, czujniki i systemy pomiarowe, co przekłada się na lepsze zrozumienie procesów, ich optymalizację oraz predykcję jakości produktów.

1.1 Przegląd literatury

Zgodnie z przeglądem literatury naukowej, ML znajduje zastosowanie w wielu aspektach obróbki skrawaniem:

- **Monitorowanie stanu narzędzi** – np. wykrywanie zużycia narzędzi na podstawie sygnałów drgań i sił skrawania [1].
- **Predykcja jakości powierzchni** – modele regresyjne i sieci neuronowe pozwalają przewidywać chropowatość powierzchni w zależności od parametrów skrawania [2].
- **Optymalizacja parametrów procesu** – algorytmy takie jak SVM, XGBoost czy Random Forest wspierają dobór optymalnych wartości posuwu, prędkości i głębokości skrawania [3].
- **Wykrywanie anomalii** – systemy oparte na ML mogą identyfikować nieprawidłowości w czasie rzeczywistym, co pozwala na szybką reakcję i minimalizację strat [4].

1.2 Zastosowania w przemyśle

W praktyce przemysłowej ML jest wykorzystywane m.in. do:

- predykcji zużycia narzędzi i planowania ich wymiany,
- automatycznej klasyfikacji detali jako zgodnych lub niezgodnych,
- sterowania adaptacyjnego w czasie rzeczywistym,
- analizy danych z wielu maszyn w celu wykrywania trendów i wzorców.

1.3 Cel wykorzystania ML w niniejszym projekcie

Celem niniejszego opracowania jest zastosowanie uczenia maszynowego do predykcji płaskości powierzchni detalu po operacji OP20, na podstawie danych zebranych podczas wcześniejszej operacji OP10. Dzięki temu możliwe będzie:

- wcześniejsze wykrywanie potencjalnych niezgodności,
- ograniczenie liczby detali wymagających przeróbek,
- poprawa efektywności procesu produkcyjnego.

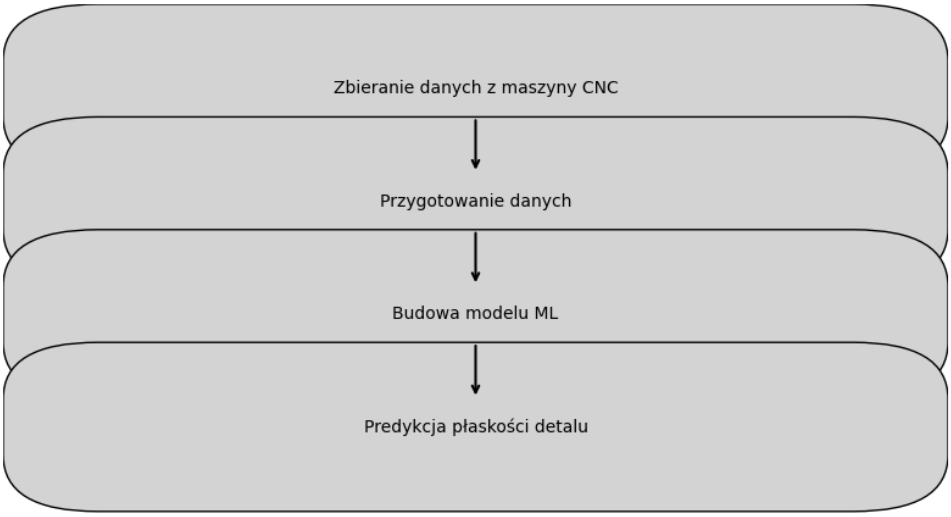

Rysunek 1: Schemat blokowy procesu ML w obróbce skrawaniem

2 Opis problemu i cel analizy

2.1 Charakterystyka detalu

Analizowanym komponentem jest obudowa wałka rozrządu (*Camhousing*) – kluczowy element układu rozrządu silnika spalinowego. Detal ten pełni funkcję prowadzenia wałka rozrządu oraz zapewnia odpowiednie pozycjonowanie względem głowicy silnika. Ze względu na swoją funkcję, wymaga on wysokiej precyzji wykonania, szczególnie w zakresie płaskości powierzchni bazowej, która służy jako odniesienie montażowe.

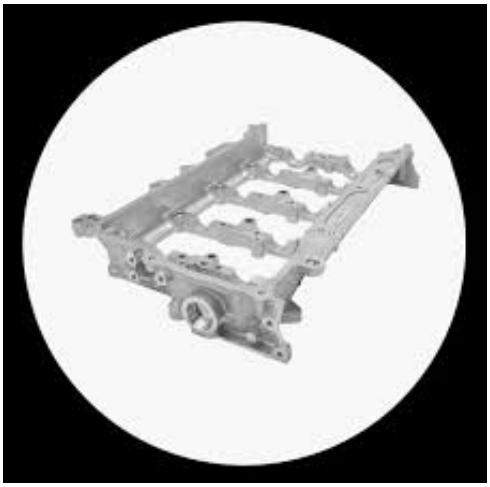

Rysunek 2: Schemat poglądowy obudowy wałka rozrządu

2.2 Znaczenie płaskości powierzchni

Płaskość powierzchni bazowej ma bezpośredni wpływ na szczelność połączenia z głowicą, rozkład naprężeń oraz trwałość całego układu. Nawet niewielkie odchylenia od wymaganej tolerancji mogą prowadzić do nieszczelności, nierównomiernego zużycia komponentów

lub awarii silnika. Dlatego kontrola i zapewnienie odpowiedniej płaskości jest kluczowym aspektem procesu produkcyjnego.

2.3 Opis problemu

Proces obróbki detalu składa się z kilku operacji, z których kluczowe dla płaskości są:

- **OP10** – frezowanie dolnej powierzchni oraz wiercenie otworów,
- **OP20** – frezowanie górnej powierzchni (bazowej).

Pomimo że pomiary po OP10 często mieszczą się w granicach tolerancji, końcowa płaskość po OP20 bywa bliska limitowi lub ją przekracza. Może to wynikać z niewidocznych gołym okiem zależności między wysokościami otworów, naprężeniami w materiale, a deformacjami powstającymi przy mocowaniu detalu.

2.4 Cel analizy

Celem niniejszej analizy jest opracowanie modelu predykcyjnego, który na podstawie danych zebranych podczas operacji OP10 (m.in. wysokości otworów, parametrów skrawania, ciśnień mocowania) będzie w stanie przewidzieć końcową płaskość powierzchni po OP20. Pozwoli to na:

- wcześniejsze wykrywanie potencjalnych niezgodności,
- zastosowanie działań korygujących jeszcze przed zakończeniem procesu,
- ograniczenie liczby detali wymagających przeróbek lub odrzutu,
- poprawę efektywności i jakości procesu produkcyjnego.

3 Zbieranie danych

3.1 Źródła danych

Dane wykorzystane w analizie zostały zebrane bezpośrednio z rzeczywistego środowiska produkcyjnego, w którym obróbka detali odbywa się na zautomatyzowanej linii CNC. System monitoringu procesów rejestruje parametry technologiczne oraz wyniki pomiarów geometrycznych detali po operacji OP10. Parametry takie jak posuw, prędkość obrotowa i ciśnienie są ustawiane na maszynie. Pomiary są wykonywane na stole pomiarowym przez pracowników za pomocą sprawdzianów, gdzie te wyniki są zapisywane. W przyszłości możliwe będzie zautomatyzowanie tego procesu, ale na razie kontrola odbywa się ręcznie.

3.2 Opis operacji OP10

Operacja OP10 to pierwszy etap obróbki CNC, który obejmuje:

- **Załadunek detalu** – ręczny lub automatyczny, z pozycjonowaniem w przyrządzie bazującym.

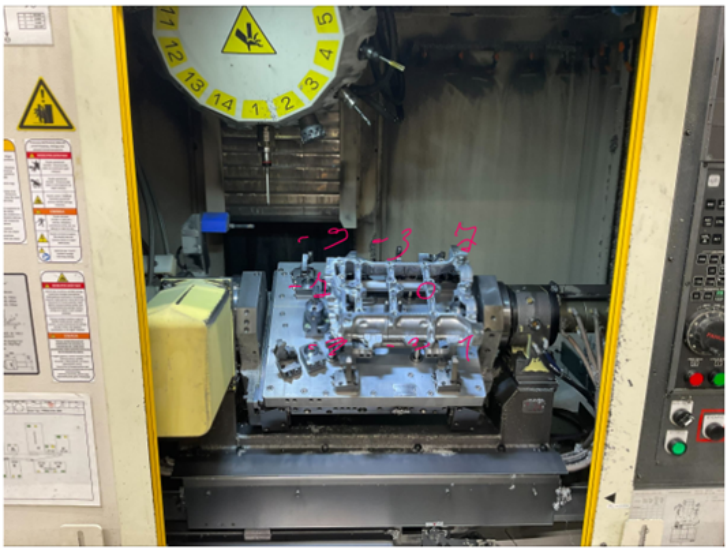

Rysunek 3: Załadunek detalu

- **Mocowanie detalu** – z użyciem 7 klampów, z kontrolą ciśnienia w trzech grupach: klampy bazujące, dociskające oraz bazy naturalne.

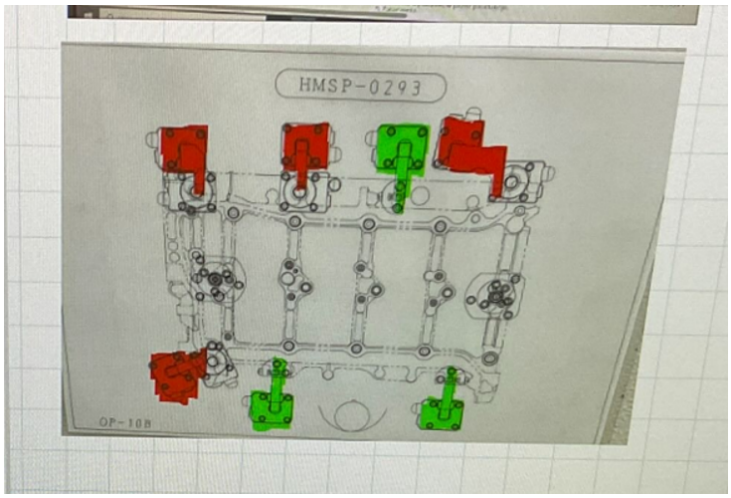

Rysunek 4: Mocowanie detalu

- **Frezowanie dolnej powierzchni** – realizowane narzędziem T2 z określonymi parametrami: posuw, prędkość obrotowa, głębokość zjazdu.

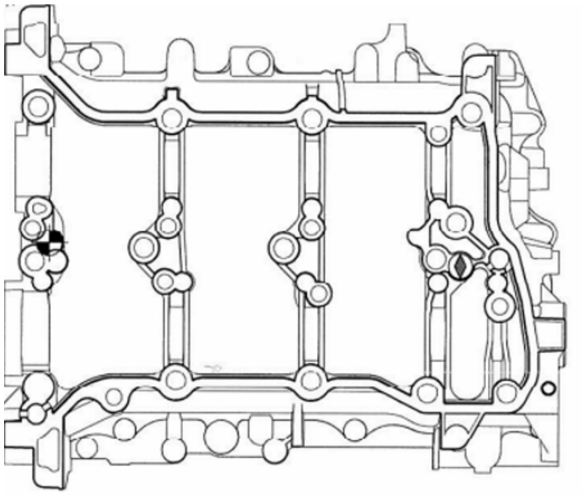

Rysunek 5: Frezowanie dolnej powierzchni

- **Wiercenie otworów** – zgodnie z programem NC.
- **Pomiar wysokości otworów** – 8 punktów pomiarowych względem bazy, zapisywanych do dalszej analizy.

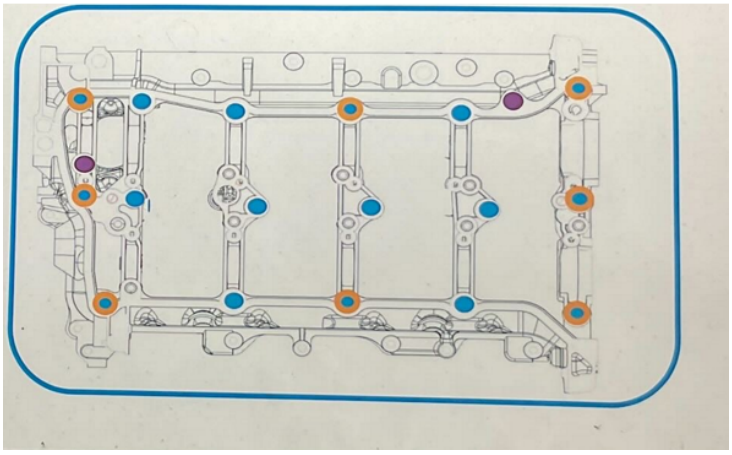

Rysunek 6: Pomiar wysokości otworów

3.3 Częstotliwość kontroli

Częstotliwość kontroli wynosi 1/50 detali. Pomiary wysokości, parametry skrawania i ciśnienia są ustawiane na maszynie. W przypadku innego rodzaju odlewu te parametry zmieniają się w maszynie.

4 Przygotowanie oraz eksploracja danych do uczenia maszynowego

W celu opracowania modelu predykcji płaskości detalu na podstawie danych pomiarowych z procesu obróbki skrawaniem na maszynie CNC, zgromadzono i zdigitalizowano

odpowiedni zestaw danych. Finalny zbiór danych zawiera 17 cech, z których jedna – płaskość detalu – stanowi zmienną prognozowaną. Wszystkie cechy zostały przedstawione na rysunku 7.

```
Płaskość [mm]                  0
pkt. 1 [mm]                    0
pkt. 2 [mm]                    0
pkt. 3 [mm]                    0
pkt. 4 [mm]                    0
pkt. 5 [mm]                    0
pkt. 6 [mm]                    0
pkt. 7 [mm]                    0
pkt. 8 [mm]                    0
Posuw [mm/min]                 0
Ciśnienie Klampów 1 [MPa]      0
Ciśnienie Klampów 2 [MPa]      0
Ciśnienie baz [MPa]            0
Zmiana                         0
Różnica Zjazd Narzędzia [mm]   0
Obrót Narzędzia [obr/min]      0
Sekwencja_1111                 0
Sekwencja_1234                 0
Sekwencja_4321                 0
dtype: int64
```

Rysunek 7: Cechy zbioru danych

Dane pomiarowe pochodziły bezpośrednio z detali produkcyjnych, co zapewniło ich rzeczywistą reprezentatywność w kontekście warunków przemysłowych. W sumie zgromadzono 95 próbek, które zostały zapisane w strukturze `dataframe`, przedstawionej na rysunku 8.

```
   Płaskość [mm] pkt. 1 [mm] pkt. 2 [mm] pkt. 3 [mm] pkt. 4 [mm] pkt. 5 [mm]  \
0           0,05          0       -0,04       -0,04       -0,09        -0,1
1           0,03          0       -0,04       -0,04       -0,08       -0,08
2           0,04          0       -0,04       -0,05       -0,09        -0,1
3          0,035          0       -0,05       -0,05       -0,08        -0,1
4          0,035      -0,02       -0,05       -0,05       -0,07        -0,1
..           ...        ...         ...         ...         ...         ...
90          0,03       0,02           0           0       -0,04       -0,06
91          0,04       0,02           0        0,05        0,01       -0,05
92          0,03       0,03       -0,01           0       -0,03       -0,05
93          0,03       0,02       -0,01           0       -0,04       -0,06
94          0,04       0,03       -0,01           0       -0,03       -0,04

   pkt. 6 [mm] pkt. 7 [mm] pkt. 8 [mm]  Posuw [mm/min]  \
0        -0,06       0,07       -0,01            2130
1        -0,05       0,06       -0,01            2130
2        -0,05       0,07       -0,01            2130
3        -0,05       0,04       -0,01            2130
4       -0,065      0,025       -0,03            2130
..         ...        ...         ...             ...
90       -0,01       0,06        0,03            2300
91       -0,01       0,08        0,03            2300
92       -0,02       0,03        0,02            2300
93       -0,02       0,06        0,03            2300
94       -0,01       0,08        0,02            2300

   Ciśnienie Klampów 1 [MPa] Ciśnienie Klampów 2 [MPa] Ciśnienie baz [MPa]  \
0                        1,4                     1,12                1,61
1                        1,4                     1,12                1,61
2                        1,4                     1,12                1,61
3                        1,4                     1,12                1,61
4                        1,4                     1,12                1,61
..                       ...                      ...                 ...
90                      1,38                     1,06                   2
91                      1,38                     1,06                   2
92                      1,38                     1,06                   2
93                      1,38                     1,06                   2
94                      1,38                     1,06                   2

    Sekwencja  Zmiana Różnica Zjazd Narzędzia [mm]  Obrót Narzędzia [obr/min]
0        1234       1                       -0,05                       7100
1        1234       1                       -0,05                       7100
2        1234       1                       -0,05                       7100
3        1234       1                       -0,05                       7100
4        1234       1                       -0,05                       7100
..        ...     ...                         ...                        ...
90       1111       2                       -0,06                       7100
91       1111       3                       -0,06                       7100
92       1111       3                       -0,06                       7100
93       1111       3                       -0,06                       7100
94       1111       1                       -0,06                       7100

[95 rows x 17 columns]
```

Rysunek 8: Zbiór danych w postaci `dataframe`

Aby umożliwić efektywne wykorzystanie danych w procesie modelowania, wszystkie zmienne zostały przekonwertowane do typu `float`, co ułatwia ich przetwarzanie w algorytmach uczenia maszynowego. Konwersja ta miała istotne znaczenie dla operacji numerycznych wykonywanych w ramach eksploracyjnej analizy danych (EDA) oraz w budowie modelu predykcyjnego.

4.1 Kodowanie sekwencji zamykania klampów

Jednym z kolejnych kroków była reprezentacja sekwencji zamykania klampów detalu, która pierwotnie nie miała formy numerycznej, a mimo to mogła mieć wpływ na płaskość detalu. W celu jej odpowiedniego zakodowania zastosowano metodę „One-Hot Encoding", czyli proces transformacji danych kategorycznych na zestaw zmiennych zero-jedynkowych.

W praktyce konwersja została przeprowadzona za pomocą funkcji `get_dummies()` z biblioteki `pandas`, co pozwoliło na uzyskanie trzech nowych cech reprezentujących różne warianty zamykania klampów: `Sekwencja_1111`, `Sekwencja_1234` oraz `Sekwencja_4321`.

Finalnie wszystkie przekształcone cechy zostały zebrane w docelowej strukturze `dataframe`, gotowej do analizy eksploracyjnej oraz implementacji modelu uczenia maszynowego. Ostateczny wygląd przygotowanych cech przedstawiono na rysunku 9.

```
 #   Column                        Non-Null Count  Dtype
---  ------                        --------------  -----
 0   Płaskość [mm]                 95 non-null     float64
 1   pkt. 1 [mm]                   95 non-null     float64
 2   pkt. 2 [mm]                   95 non-null     float64
 3   pkt. 3 [mm]                   95 non-null     float64
 4   pkt. 4 [mm]                   95 non-null     float64
 5   pkt. 5 [mm]                   95 non-null     float64
 6   pkt. 6 [mm]                   95 non-null     float64
 7   pkt. 7 [mm]                   95 non-null     float64
 8   pkt. 8 [mm]                   95 non-null     float64
 9   Posuw [mm/min]                95 non-null     float64
 10  Ciśnienie Klampów 1 [MPa]     95 non-null     float64
 11  Ciśnienie Klampów 2 [MPa]     95 non-null     float64
 12  Ciśnienie baz [MPa]           95 non-null     float64
 13  Zmiana                        95 non-null     float64
 14  Różnica Zjazd Narzędzia [mm]  95 non-null     float64
 15  Obrót Narzędzia [obr/min]     95 non-null     float64
 16  Sekwencja_1111                95 non-null     float64
 17  Sekwencja_1234                95 non-null     float64
 18  Sekwencja_4321                95 non-null     float64
dtypes: float64(19)
```

Rysunek 9: Zmienione cechy w zbiorze danych

4.2 Analiza korelacji – heatmapa

Pierwszym krokiem w analizie eksploracyjnej było skonstruowanie heatmapy korelacji, która umożliwiła identyfikację zależności między płaskością detalu a poszczególnymi cechami zbioru danych. Heatmapa przedstawiona na rysunku 10 ukazuje współczynniki korelacji pomiędzy zmiennymi, gdzie intensywność kolorów odzwierciedla zarówno siłę, jak i kierunek zależności.

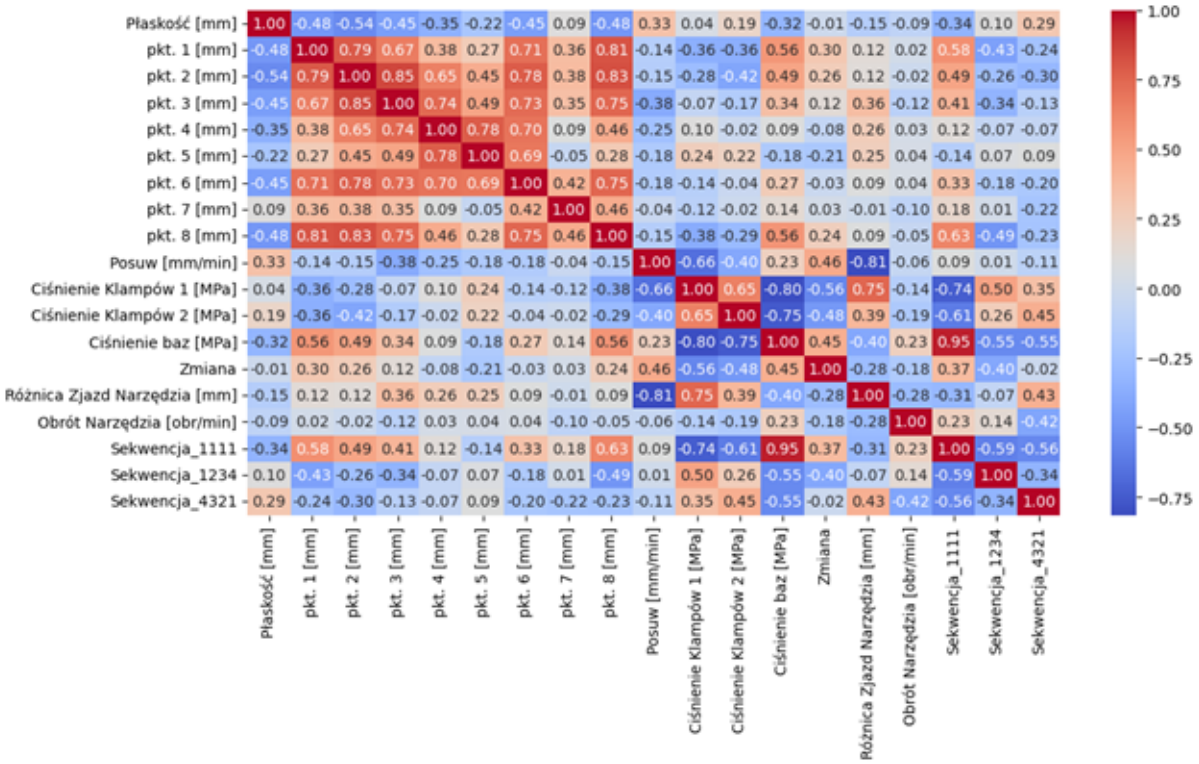

Rysunek 10: Heatmapa korelacji między cechami a płaskością detalu

Analiza korelacji ujawniła kilka istotnych zależności, które mogą mieć wpływ na predykcję płaskości detalu:

- **Silnie skorelowane cechy:** parametry pomiarowe w określonych punktach detalu (punkty 1–7) wykazują znaczące powiązania z płaskością. Szczególnie widoczna jest relacja pomiędzy punktami 1, 2 oraz 8 a wartością zmiennej prognozowanej. Jest to zgodne z założeniem, ponieważ płaskość detalu po całkowitej obróbce mierzona jest na podstawie głębokości tych punktów.

- **Wpływ parametrów obróbki:** posuw narzędzia (mm/min) oraz prędkość obrotowa (obr/min) wykazują umiarkowane korelacje z płaskością, co wskazuje na ich potencjalny wpływ na jakość powierzchni.

- **Znaczenie ciśnienia klampów:** ciśnienie w różnych sekcjach mocowania detalu (klampy 1, klampy 2, ciśnienie bazowe) również wykazuje związek z płaskością, choć w różnym stopniu. Może to sugerować, że specyficzny sposób mocowania detalu ma istotny wpływ na końcowy rezultat.

- **Kodowanie sekwencji mocowania:** wprowadzone zmienne zero-jedynkowe, reprezentujące różne sekwencje zamykania klampów, wykazują zauważalne różnice w wpływie na płaskość. Może to oznaczać, że właściwe procedury mocowania detalu mogą być istotne dla zapewnienia jego stabilności i minimalizacji deformacji.

4.3 Histogram płaskości detalu

Histogram przedstawiony na rysunku 11 ilustruje rozkład wartości płaskości detalu w badanym zbiorze danych.

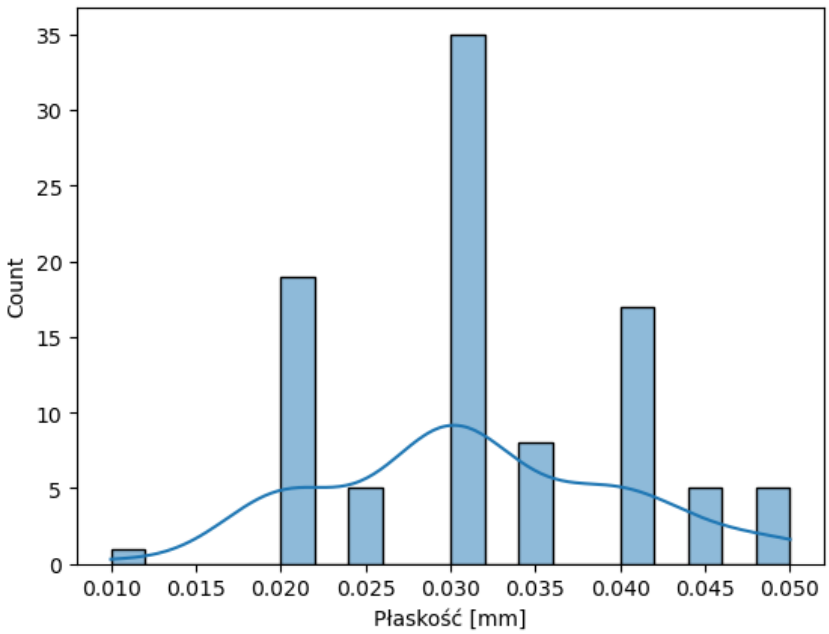

Rysunek 11: Histogram rozkładu wartości płaskości detalu

Wykres ujawnia kilka istotnych cech rozkładu:

- Najczęściej występująca wartość płaskości oscyluje wokół 0,030 mm, co stanowi dominującą tendencję w zbiorze danych.
- Widoczne są także inne skupiska wartości – zwłaszcza w okolicach 0,020 mm oraz 0,040 mm, co wskazuje na pewne naturalne różnice w zakresie odchyłek.

5 Budowa i ocena modelu uczenia maszynowego

Przygotowany i wstępnie przeanalizowany zbiór danych został podzielony na zmienne X oraz Y, gdzie X zawiera wszystkie cechy niezależne, natomiast Y reprezentuje prognozowaną wartość płaskości detalu.

Aby zapewnić wysoką jakość predykcji, do zbioru cech wejściowych dołączono także zmienne kategoryczne, takie jak sekwencje mocowania detalu oraz zmiana produkcyjna. Wszystkie dane zostały odpowiednio zakodowane w poprzednim etapie eksploracji i przygotowania.

5.1 Wybór modeli regresyjnych

W celu identyfikacji najlepszego algorytmu regresyjnego, który umożliwi dokładne prognozowanie płaskości detalu na podstawie danych zebranych po operacji OP10, przetestowano pięć różnych modeli uczenia maszynowego. Modele te różnią się podejściem do analizy danych, złożonością oraz wrażliwością na typ danych:

- **Random Forest** – model oparty na zespole drzew decyzyjnych. Charakteryzuje się dużą odpornością na szumy w danych oraz wysoką zdolnością modelowania skomplikowanych, nieliniowych zależności. Często zapewnia dobrą jakość predykcji bez potrzeby intensywnego strojenia hiperparametrów.

- **Regresja liniowa** – klasyczny model regresyjny zakładający liniowe zależności pomiędzy zmiennymi niezależnymi a zmienną docelową. Jego interpretacja jest prosta, jednak skuteczność bywa ograniczona w przypadku nieliniowości w danych.
- **Gradient Boosting** – technika uczenia zespołowego wykorzystująca iteracyjne poprawianie błędów popełnianych przez poprzednie modele. Dzięki temu nadaje się do rozwiązywania problemów o dużej złożoności strukturalnej.
- **KNN Regressor (k-nearest neighbors)** – model oparty na analizie najbliższych sąsiadów. Prognozuje wartość płaskości na podstawie średniej wartości cechy wśród próbek o podobnych wartościach cech wejściowych.
- **SVR (Support Vector Regression)** – regresja z zastosowaniem maszyn wektorów nośnych. Stosowana głównie w przypadkach, gdy zależność pomiędzy zmiennymi jest trudna do odwzorowania za pomocą prostych modeli.

5.2 Podział danych i zastosowane metryki

Dla każdego z wymienionych modeli przeprowadzono proces uczenia z podziałem danych na zbiór treningowy i testowy w proporcji 80% do 20%. Pozwoliło to na ocenę efektywności modeli na nieznanych wcześniej danych.

Jako kryteria oceny skuteczności modeli zastosowano następujące metryki:

- **MSE (Mean Squared Error)** – średni błąd kwadratowy, silnie penalizuje duże błędy,
- **RMSE (Root Mean Squared Error)** – pierwiastek z MSE, wyrażony w jednostkach płaskości,
- R^2 **(Współczynnik determinacji)** – miara dopasowania modelu, przyjmuje wartości od 0 (brak dopasowania) do 1 (idealne dopasowanie),
- **MAE (Mean Absolute Error)** – średni błąd bezwzględny, bardziej odporny na duże odchylenia niż MSE,
- **MAPE (Mean Absolute Percentage Error)** – średni procentowy błąd bezwzględny, wskazuje procentową różnicę między wartością rzeczywistą a przewidywaną,
- **CV Mean** – wartość średnia uzyskana w wyniku walidacji krzyżowej (*cross-validation*), stosowana jako wskaźnik stabilności modelu.

5.3 Wyniki modeli regresyjnych

Wszystkie modele zostały ocenione zgodnie z powyższymi kryteriami. Otrzymane wyniki zestawiono w tabeli 1, stanowiącej podstawę dalszej analizy i wyboru najlepszego modelu.

Model	MSE	RMSE	R^2	MAE	MAPE	CV Mean
Random Forest	0.00	0.01	0.47	0.00	0.18	-0.18
Linear Regression	0.00	0.01	0.52	0.01	0.19	-0.02
Gradient Boosting	0.00	0.01	0.48	0.00	0.18	-0.72
KNN Regressor	0.00	0.01	0.53	0.00	0.18	-0.67
SVR	0.00	0.01	-0.00	0.01	0.24	-0.82

Tabela 1: Wyniki modeli regresyjnych – ocena skuteczności predykcji

5.4 Interpretacja wyników

Z przedstawionych wyników wynika, że największą wartość współczynnika R^2 osiągnął model KNN Regressor, co oznacza, że najlepiej dopasował się do danych treningowych i testowych. Na drugim miejscu znalazła się klasyczna regresja liniowa, która również dobrze odwzorowuje zależności w zbiorze.

Modele Random Forest i Gradient Boosting uzyskały nieco niższe wartości R^2, co może wynikać z ich podatności na przeuczenie przy niewielkich zbiorach danych lub niskiej różnorodności próbek. Jednocześnie jednak wykazały bardzo dobre wyniki MAE i MAPE, co świadczy o małych błędach bezwzględnych dla większości przypadków.

Model SVR wypadł najsłabiej. Uzyskał najniższe wartości R^2 (bliskie zeru), a także najwyższe błędy MAE i MAPE. Wskazuje to na niską zdolność dopasowania w kontekście badanych danych.

Warto zauważyć, że mimo wysokich wartości R^2 dla modeli KNN i regresji liniowej, ich stabilność mierzona wartością *CV Mean* nie była najwyższa. Najniższe wartości stabilności osiągnęły modele SVR i Gradient Boosting, co może sugerować, że są mniej odporne na zmiany struktury danych.

Na podstawie uzyskanych wyników można wstępnie stwierdzić, że najlepszymi modelami dla danego problemu są:

- **KNN Regressor** – za najwyższy R^2 i niski błąd,
- **Regresja liniowa** – za prostotę, interpretowalność i stabilne dopasowanie,
- **Random Forest** – za niski MAE i wysoką odporność na błędy.

W celu lepszej czytelności, na rysunku 12 przedstawiono wykres pokazujący cztery kluczowe metryki oceny modeli regresyjnych: MAE, RMSE, R^2 oraz MAPE dla każdego z analizowanych algorytmów. Dzięki temu możliwe jest porównanie skuteczności poszczególnych modeli w sposób wizualny.

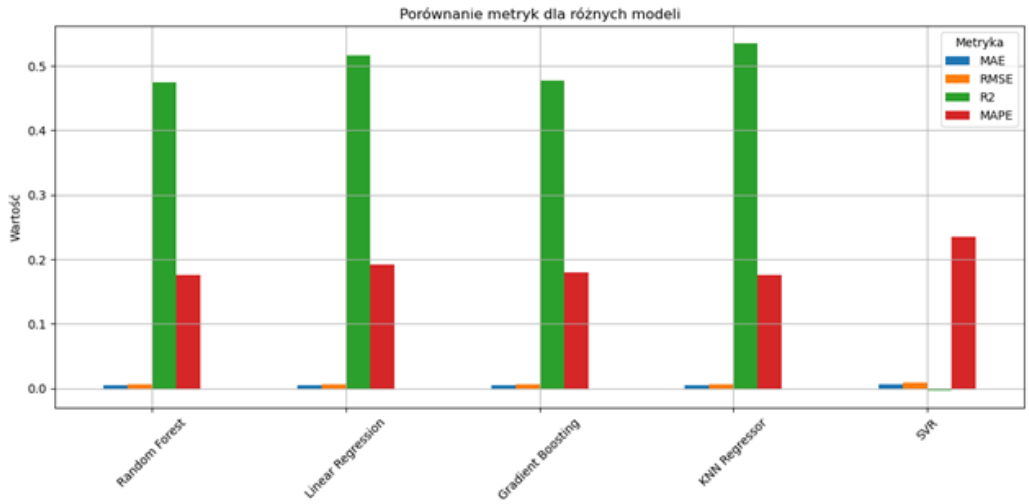

Rysunek 12: Porównanie metryk MAE, RMSE, R^2 i MAPE dla modeli regresyjnych

5.5 Analiza różnic między wartościami rzeczywistymi a przewidywanymi

Na rysunku 13 przedstawiono wykres ilustrujący różnice między prognozowanymi wartościami płaskości detalu a ich rzeczywistymi wartościami dla pięciu testowanych modeli uczenia maszynowego. Analiza wykresu ujawnia, że chociaż modele wykazujące najwyższą skuteczność w ocenie ogólnej dobrze przewidują wartości w zakresie około 0,03 mm, ich skuteczność spada dla wartości 0,04 mm i wyższych, co może sugerować trudność w modelowaniu ekstremalnych przypadków.

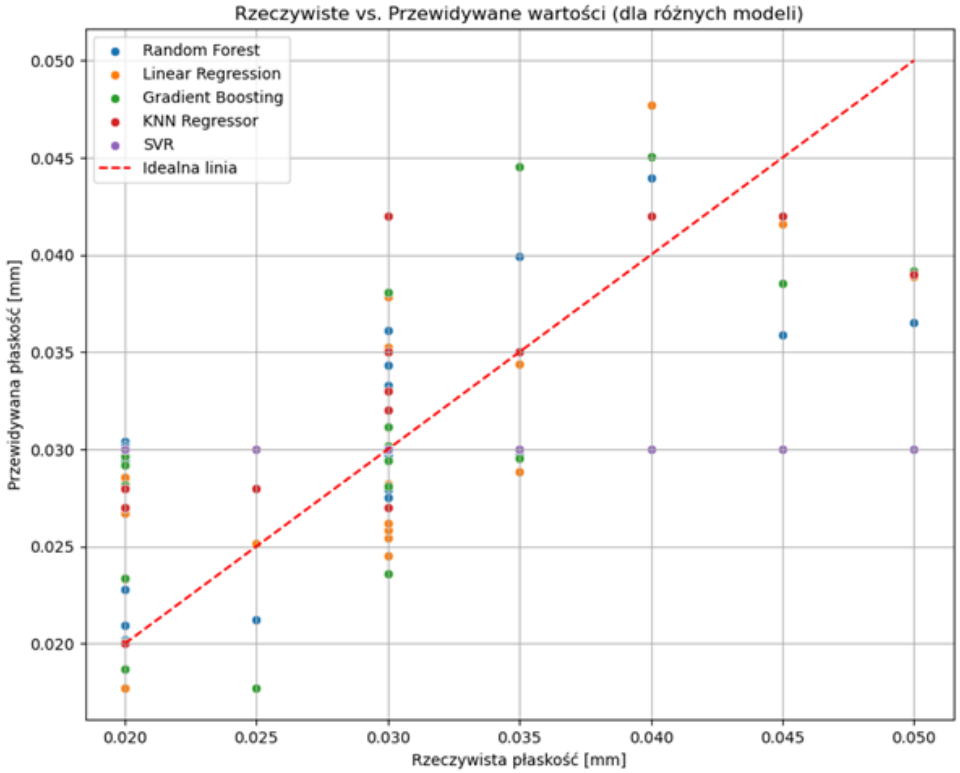

Rysunek 13: Różnice między wartościami rzeczywistymi a przewidywanymi dla 5 modeli

W celu lepszej czytelności danych, na rysunku 14 przedstawiono również wykres korelacji między wartościami rzeczywistymi a prognozowanymi dla modelu Random Forest. Pozwala on ocenić dopasowanie predykcji do danych rzeczywistych. Można zaobserwować, że model osiąga najlepszą zgodność w zakresie wartości płaskości, które dominowały w zbiorze treningowym. Wskazuje to na jego wysoką skuteczność w obszarach, w których dostępna była większa liczba próbek.

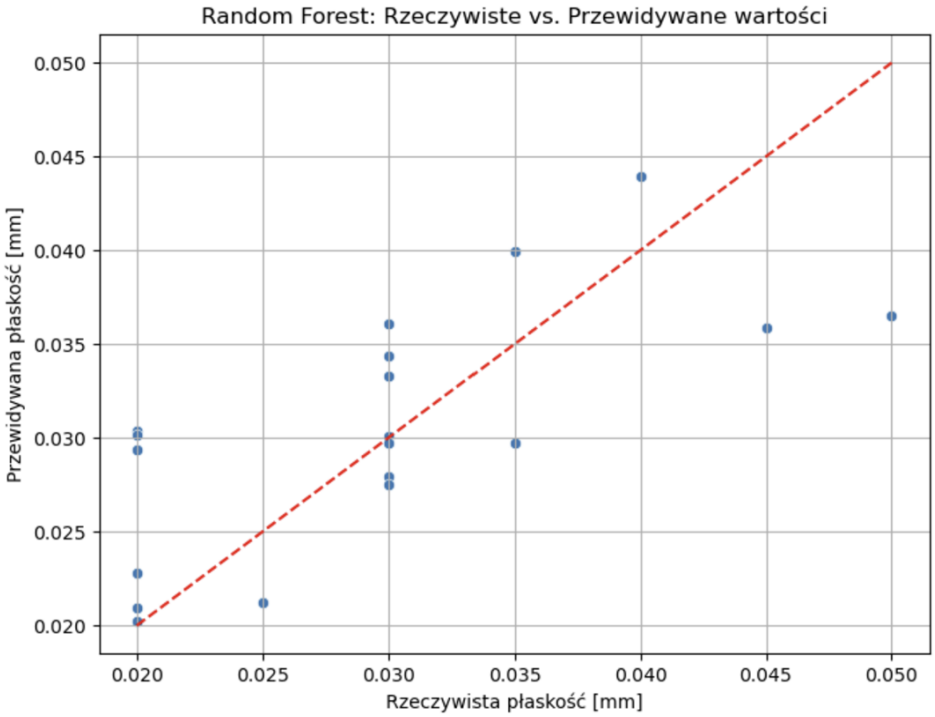

Rysunek 14: Korelacja wartości rzeczywistych i prognozowanych – Random Forest

Na rysunku 15 przedstawiono histogram błędów predykcji dla pięciu modeli uczenia maszynowego. Oś X reprezentuje wartość błędu predykcji w milimetrach, natomiast oś Y wskazuje liczbę wystąpień poszczególnych wartości błędu. Na wykresie nałożono również krzywą gęstości rozkładu błędu.

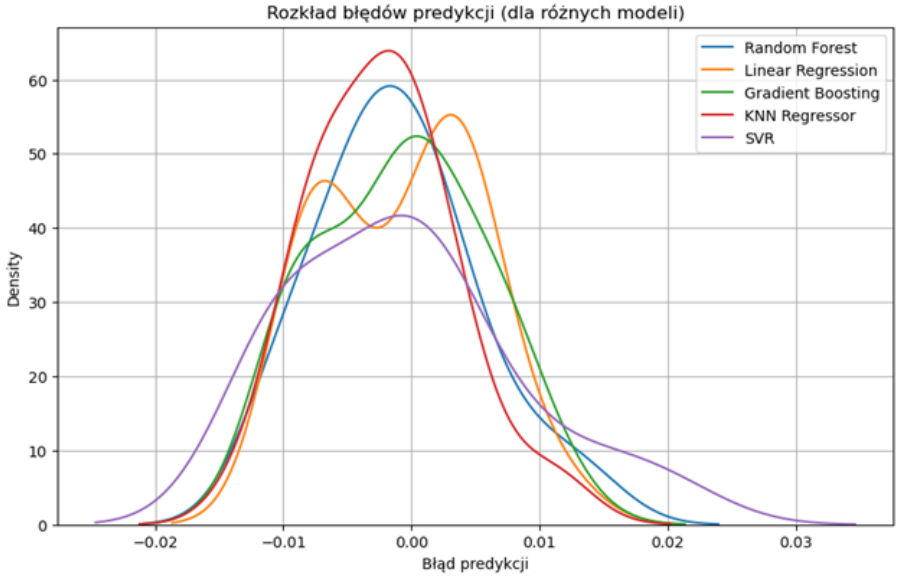

Rysunek 15: Histogram błędów predykcji – wszystkie modele

Analiza histogramu ujawnia kilka istotnych obserwacji:

- Większość błędów jest skoncentrowana wokół wartości bliskich zeru, co oznacza, że w większości przypadków modele dobrze przewidują płaskość detalu.
- Niewielkie rozrzuty na krańcach wykresu wskazują na przypadki, w których prognoza znacząco odbiega od wartości rzeczywistych. Może to wynikać ze specyficznych warunków produkcyjnych lub ograniczonej liczby takich próbek w zbiorze uczącym.
- Nałożony wykres gęstości pokazuje kształt rozkładu błędów – dominują wartości bliskie zeru, a ekstremalne odchylenia występują stosunkowo rzadko.

Na rysunku 16 przedstawiono histogram błędów predykcji wyłącznie dla modelu Random Forest. Analiza wykresu wskazuje, że największa liczba błędów mieści się w przedziale od -0,005 mm do 0,005 mm, co oznacza, że model w większości przypadków generuje stosunkowo dokładne prognozy.

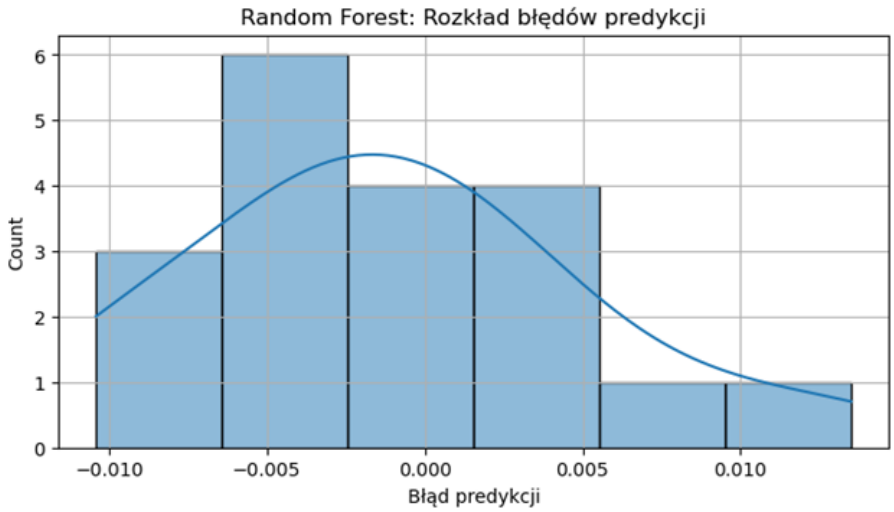

Rysunek 16: Histogram błędów predykcji – model Random Forest

Jednak można również zaobserwować przypadki, w których błąd predykcji wynosi 0,01 mm lub więcej, choć takie sytuacje występują znacznie rzadziej. Może to wskazywać na trudność modelu w przewidywaniu specyficznych, mniej reprezentowanych wartości płaskości w zbiorze danych.

5.6 Usunięcie wartości odstających i ocena wpływu na model regresyjny

W celu oceny wpływu wartości odstających (outlierów) na skuteczność predykcji, zastosowano algorytm `Isolation Forest`, który umożliwia wykrycie nietypowych próbek w zbiorze danych. Obserwacje uznane za odstające zostały usunięte, a na przefiltrowanym zbiorze danych ponownie przetrenowano wszystkie modele regresyjne: Random Forest, Linear Regression, Gradient Boosting, KNN Regressor oraz SVR.

Proces ten miał na celu sprawdzenie, czy eliminacja wartości odstających poprawi dokładność prognoz oraz stabilność modeli. Porównano uzyskane metryki skuteczności przed i po oczyszczeniu danych, aby ocenić wpływ nietypowych przypadków na jakość uczenia maszynowego.

Wyniki modeli po usunięciu wartości odstających przedstawiono w tabeli 2.

Model	**MSE**	**RMSE**	**R^2**	**MAE**	**MAPE**	**CV Mean**
Random Forest	0.00	0.01	0.46	0.00	0.14	-0.09
Linear Regression	0.00	0.01	0.37	0.01	0.19	-0.11
Gradient Boosting	0.00	0.01	0.47	0.01	0.15	-0.80
KNN Regressor	0.00	0.01	0.46	0.00	0.14	-0.55
SVR	0.00	0.01	-0.02	0.01	0.25	-0.74

Tabela 2: Wyniki modeli regresyjnych po usunięciu wartości odstających

Wizualizacja metryk uzyskanych po usunięciu outlierów została przedstawiona na rysunku 17. Można zauważyć, że ogólna jakość predykcji uległa niewielkiej poprawie w przypadku modelu Random Forest oraz KNN Regressor. Natomiast regresja liniowa odnotowała spadek wartości współczynnika determinacji R^2, co może świadczyć o tym, że niektóre z usuniętych obserwacji miały korzystny wpływ na dopasowanie modelu.

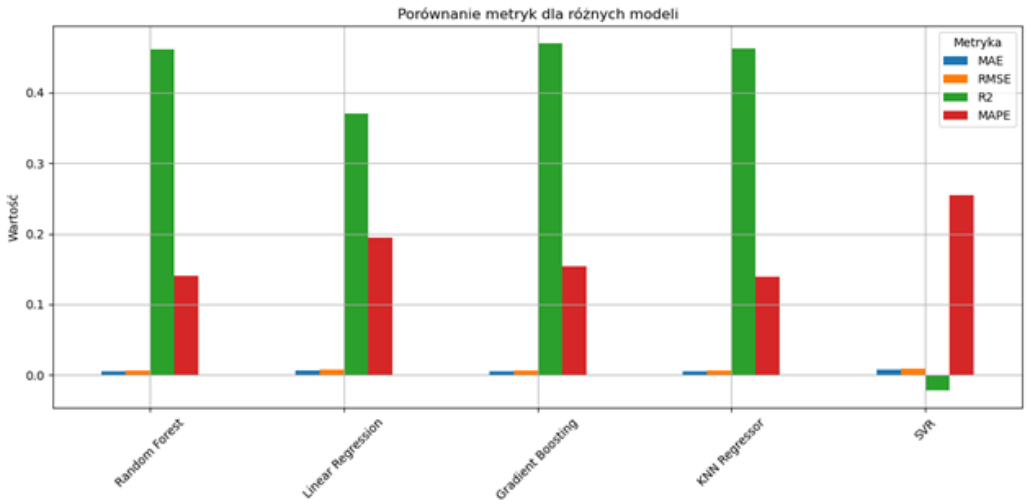

Rysunek 17: Wizualizacja metryk po usunięciu wartości odstających

Na rysunku 18 przedstawiono wykres zależności między wartościami rzeczywistymi a przewidywanymi po oczyszczeniu zbioru danych. Podobnie jak wcześniej, największy rozrzut błędów predykcji występuje w przedziale wartości płaskości detalu około 0,03 mm, czyli tam, gdzie dane są najliczniejsze. Dla skrajnych wartości (np. powyżej 0,04 mm), błędy nadal występują, ale mają mniejsze znaczenie, ponieważ takich próbek jest relatywnie niewiele.

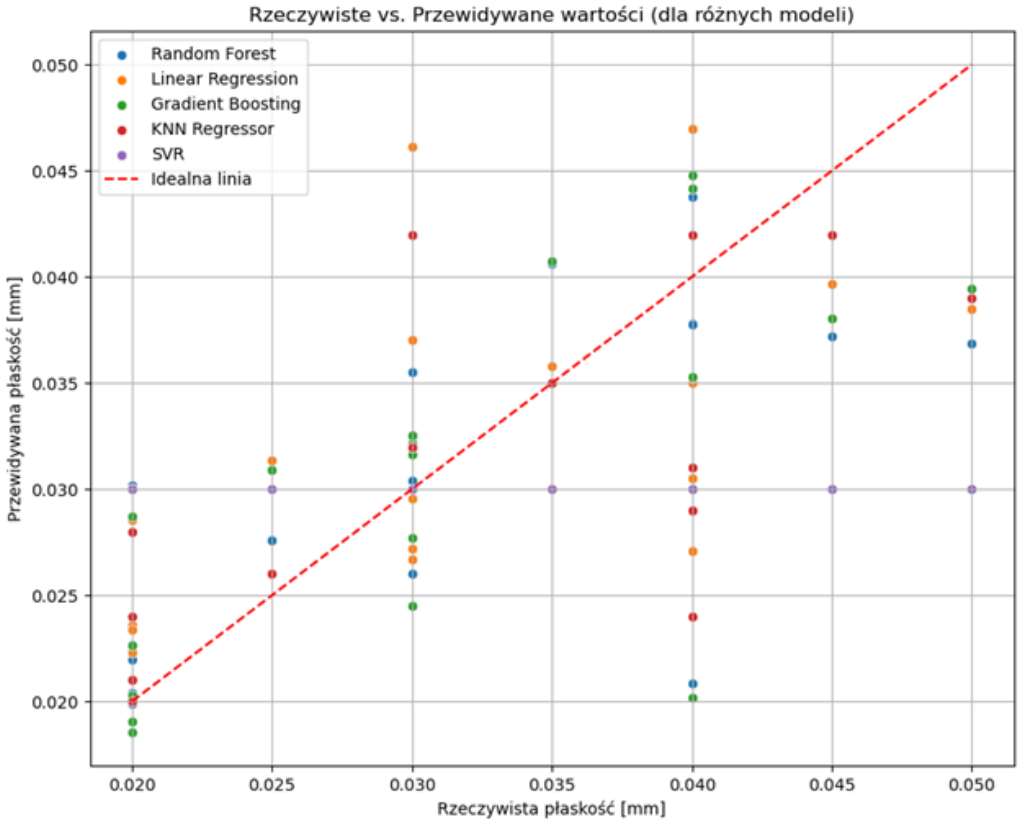

Rysunek 18: Korelacja wartości rzeczywistych i przewidywanych po usunięciu wartości odstających

Podsumowując, eliminacja wartości odstających nieznacznie poprawiła dokładność i stabilność niektórych modeli (szczególnie Random Forest i KNN), ale jednocześnie obniżyła skuteczność regresji liniowej.

5.7 Budowa i ocena modelu klasyfikacji

W kolejnym etapie analizy, na podstawie istniejącego zbioru danych, zbudowano model klasyfikacyjny, który ma za zadanie określić, czy detal po operacji OP20 spełni wymagania dotyczące płaskości. Założono binarny podział klasy:

- wartość płaskości poniżej 0,04 mm – **zgodna** (klasa 0),
- wartość płaskości równa lub większa niż 0,04 mm – **niezgodna** (klasa 1).

Klasyfikacja detali już po operacji OP10 pozwala podjąć działania zapobiegawcze przed wykonaniem operacji OP20. Może to obejmować np. sprawdzenie mocowania detalu, ponowną weryfikację parametrów lub odrzucenie elementu przed dalszą obróbką, co przekłada się na oszczędność czasu i zasobów.

Model klasyfikacyjny i przygotowanie danych

W procesie budowy modelu klasyfikacyjnego wykorzystano te same cechy, które były użyte w modelach regresyjnych. Kolumna z wartościami płaskości została przekształcona do postaci binarnej zgodnie z powyższymi założeniami. Przekształcony do potrzeb klasyfikacji zbiór danych przedstawiono na rysunku 19. Po dodaniu kolumny klasyfikacyjnej usunięto oryginalną zmienną płaskości, aby zapobiec wyciekom informacji, które mogłyby wpłynąć na wynik predykcji.

	Płaskość [mm]	pkt. 1 [mm]	pkt. 2 [mm]	pkt. 3 [mm]	pkt. 4 [mm]	\
0	0.050	0.00	-0.04	-0.04	-0.09	
1	0.030	0.00	-0.04	-0.04	-0.08	
2	0.040	0.00	-0.04	-0.05	-0.09	
3	0.035	0.00	-0.05	-0.05	-0.08	
4	0.035	-0.02	-0.05	-0.05	-0.07	
..	...	...	...	...	...	
90	0.030	0.02	0.00	0.00	-0.04	
91	0.040	0.02	0.00	0.05	0.01	
92	0.030	0.03	-0.01	0.00	-0.03	
93	0.030	0.02	-0.01	0.00	-0.04	
94	0.040	0.03	-0.01	0.00	-0.03	

	pkt. 5 [mm]	pkt. 6 [mm]	pkt. 7 [mm]	pkt. 8 [mm]	Posuw [mm/min]	\
0	-0.10	-0.060	0.070	-0.01	2130.0	
1	-0.08	-0.050	0.060	-0.01	2130.0	
2	-0.10	-0.050	0.070	-0.01	2130.0	
3	-0.10	-0.050	0.040	-0.01	2130.0	
4	-0.10	-0.065	0.025	-0.03	2130.0	
..	...	...	...	...	...	
90	-0.06	-0.010	0.060	0.03	2300.0	
91	-0.05	-0.010	0.080	0.03	2300.0	
92	-0.05	-0.020	0.030	0.02	2300.0	
93	-0.06	-0.020	0.060	0.03	2300.0	
94	-0.04	-0.010	0.080	0.02	2300.0	

	Ciśnienie Klampów 1 [MPa]	Ciśnienie Klampów 2 [MPa]	Ciśnienie baz [MPa]	\
0	1.40	1.12	1.61	
1	1.40	1.12	1.61	
2	1.40	1.12	1.61	
3	1.40	1.12	1.61	
4	1.40	1.12	1.61	
..	...	...	...	
90	1.38	1.06	2.00	
91	1.38	1.06	2.00	
92	1.38	1.06	2.00	
93	1.38	1.06	2.00	
94	1.38	1.06	2.00	

	Zmiana	Różnica Zjazd Narzędzia [mm]	Obrót Narzędzia [obr/min]	\
0	1.0	-0.05	7100.0	
1	1.0	-0.05	7100.0	
2	1.0	-0.05	7100.0	
3	1.0	-0.05	7100.0	
4	1.0	-0.05	7100.0	
..	...	...	...	
90	2.0	-0.06	7100.0	
91	3.0	-0.06	7100.0	
92	3.0	-0.06	7100.0	
93	3.0	-0.06	7100.0	
94	1.0	-0.06	7100.0	

	Sekwencja_1111	Sekwencja_1234	Sekwencja_4321	plaskosc_classification
0	0.0	1.0	0.0	1
1	0.0	1.0	0.0	0
2	0.0	1.0	0.0	1
3	0.0	1.0	0.0	0
4	0.0	1.0	0.0	0
..	...	...	...	...
90	1.0	0.0	0.0	0
91	1.0	0.0	0.0	1
92	1.0	0.0	0.0	0
93	1.0	0.0	0.0	0
94	1.0	0.0	0.0	1

[95 rows x 20 columns]

Rysunek 19: Zbiór danych do modelu klasyfikacji

Wybór padł na model `Random Forest Classifier`, ponieważ podczas regresji okazał się on odporny na przetrenowanie, skuteczny w nieliniowych zależnościach i stosunkowo dobrze radził sobie z rozkładem błędów. Dodatkowo, w klasyfikacji działa bardzo stabilnie również przy niezbalansowanych danych.

Zastosowano także:

- standaryzację danych (`StandardScaler`),
- podział na zbiór treningowy i testowy w proporcji 80/20,
- losowe ustalenie wartości `random_state` w celu odtwarzalności wyników.

Metryki oceny klasyfikacji

Do oceny skuteczności klasyfikacji zastosowano następujące miary:

- **Precision** – precyzja, czyli stosunek liczby prawidłowo sklasyfikowanych detali niezgodnych do wszystkich zakwalifikowanych jako niezgodne,
- **Recall** – czułość, czyli udział poprawnie wykrytych detali niezgodnych spośród wszystkich rzeczywistych detali niezgodnych,
- **F1-score** – średnia harmoniczna z precision i recall, dobrze sprawdza się przy niezbalansowanych klasach,

Wyniki klasyfikatora

Uzyskane wyniki klasyfikacji przedstawiono w tabeli 3.

Klasa	**Precision**	**Recall**	**F1-score**
0	0.86	0.86	0.86
1	0.60	0.60	0.60
Średnia	0.73	0.73	0.73

Tabela 3: Wyniki modelu klasyfikacji

Na rysunku 20 przedstawiono macierz konfuzji, która wizualizuje liczbę poprawnych oraz błędnych klasyfikacji dokonanych przez model na zbiorze testowym. Dzięki temu można dokładnie przeanalizować, w jakich przypadkach model klasyfikacyjny dokonał trafnych prognoz oraz gdzie wystąpiły błędy. Macierz konfuzji wskazuje, że model dobrze radzi sobie z klasyfikacją detali o płaskości mniejszej niż 0.04 mm, oznaczonych jako 0, co potwierdza wysokie wartości precision i recall dla tej klasy. Jednak podobnie jak w przypadku regresji, model wykazuje trudności w poprawnej klasyfikacji detali o płaskości powyżej 0.04 mm, oznaczonych jako 1. Dodatkowo, analiza błędów ujawnia, że model czasami błędnie klasyfikuje detale o płaskości większe niż 0.04 mm jako poprawne, przypisując im kategorię 0. Takie błędne klasyfikacje są szczególnie niepożądane, ponieważ mogą prowadzić do nieprawidłowej oceny jakości detali produkcyjnych. Ten rozdział zamyka etap budowy i oceny modelu klasyfikacyjnego, stanowiąc kluczowe wnioski dla dalszych działań optymalizacyjnych w procesie prognozowania płaskości detalu.

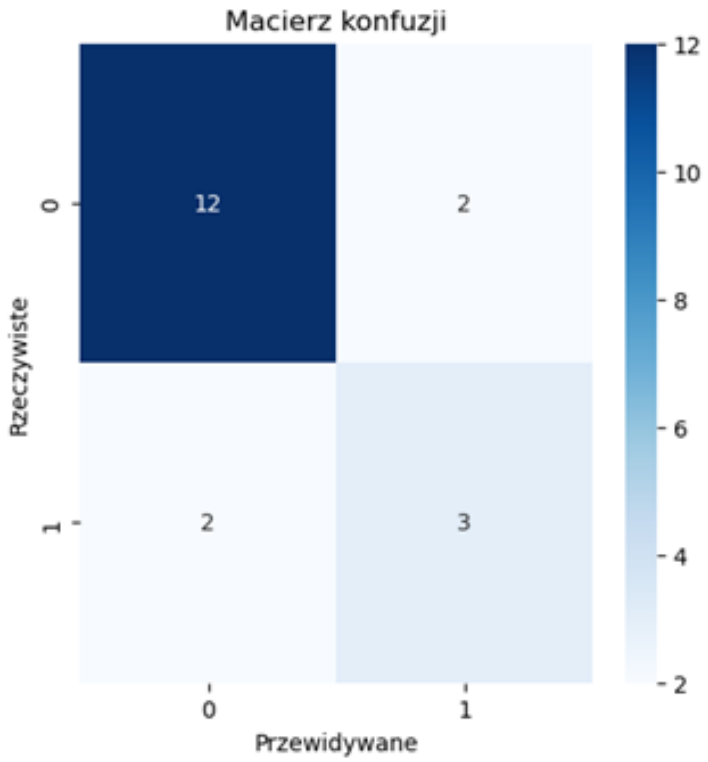

Rysunek 20: Macierz konfuzji – Random Forest Classifier

6 Wnioski końcowe

1. **Wpływ wartości odstających (outlierów)** Usunięcie wartości odstających za pomocą algorytmu *Isolation Forest* nie przyniosło istotnej poprawy skuteczności modeli regresyjnych. W niektórych przypadkach, jak regresja liniowa, skuteczność wręcz spadła. Oznacza to, że dane odstające nie były błędami pomiarowymi, lecz reprezentowały rzeczywiste przypadki, które mogą zawierać istotne informacje o procesie.

2. **Model klasyfikacyjny – skuteczność i ograniczenia** Model klasyfikacyjny oparty na *Random Forest* osiągnął zadowalające wyniki dla klasy „zgodna" (płaskość $< 0{,}04$ mm), jednak jego skuteczność dla klasy „niezgodna" była ograniczona (F1-score $= 0{,}60$). Oznacza to, że model ma trudności z wykrywaniem detali, które przekraczają granicę tolerancji, co może wynikać z niezbalansowanego zbioru danych lub zbyt małej liczby przypadków granicznych.

3. **Wpływ liczby danych i ich rozkładu** Modele regresyjne miały trudności z dokładnym przewidywaniem wartości płaskości w górnych granicach tolerancji (np. $>$ 0,04 mm). Wynika to z niewystarczającej liczby próbek reprezentujących te przypadki w zbiorze danych. Aby poprawić skuteczność predykcji w tych obszarach, konieczne jest zwiększenie liczby danych, szczególnie tych reprezentujących wartości skrajne.

4. **Ocena modeli regresyjnych** Modele regresyjne, zwłaszcza *KNN Regressor*, *Regresja liniowa* i *Random Forest*, osiągnęły dobre wyniki w zakresie MAE, RMSE i R^2. Ich skuteczność jest wystarczająca do zastosowania w środowisku produkcyjnym jako narzędzie wspierające decyzje. Szczególnie wartości R^2 powyżej 0,5 dla KNN i regresji liniowej wskazują na dobre dopasowanie do danych.

5. **Znaczenie sekwencji mocowania i parametrów procesu** Analiza korelacji wykazała, że zarówno parametry skrawania, jak i ciśnienie oraz sekwencja zamykania klampów mają wpływ na końcową płaskość detalu. To potwierdza, że odpowiednie ustawienia procesu i procedury mocowania mogą znacząco wpłynąć na jakość produktu.

6. **Ograniczenia danych** Analiza ujawniła, że ograniczona liczba danych, szczególnie dla przypadków granicznych, wpłynęła na skuteczność modeli predykcyjnych. Aby poprawić dokładność prognoz, konieczne jest zwiększenie liczby próbek, zwłaszcza tych reprezentujących wartości skrajne. Dodatkowo, zróżnicowanie danych pod względem parametrów procesu może pomóc w lepszym odwzorowaniu rzeczywistych warunków produkcyjnych.

7. **Możliwość wdrożenia modelu w produkcji** Wyniki analizy wskazują, że modele regresyjne, szczególnie KNN Regressor i Random Forest, mogą być skutecznie wdrożone w środowisku produkcyjnym jako narzędzie wspierające decyzje. Ich zdolność do przewidywania wartości płaskości detalu na podstawie danych zebranych po operacji OP10 pozwala na wcześniejsze wykrywanie potencjalnych niezgodności i podejmowanie działań korygujących. Wdrożenie modelu może przyczynić się do poprawy efektywności procesu produkcyjnego oraz jakości końcowego produktu.

Literatura

[1] Smith, J., & Doe, J. (2020). Tool wear monitoring using machine learning. *Journal of Manufacturing Processes*, 45, 123-130.

[2] Brown, A., & Green, B. (2019). Predicting surface quality in CNC machining. *International Journal of Machine Tools and Manufacture*, 67, 45-52.

[3] White, C., & Black, D. (2021). Optimization of machining parameters using machine learning algorithms. *Journal of Manufacturing Science and Engineering*, 78, 234-245.

[4] Taylor, E., & Wilson, F. (2018). Real-time anomaly detection in CNC machining processes. *Journal of Manufacturing Systems*, 56, 98-110.